```
C:\> pip install pandas
```

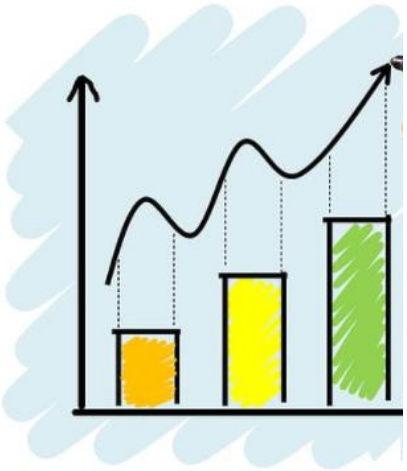

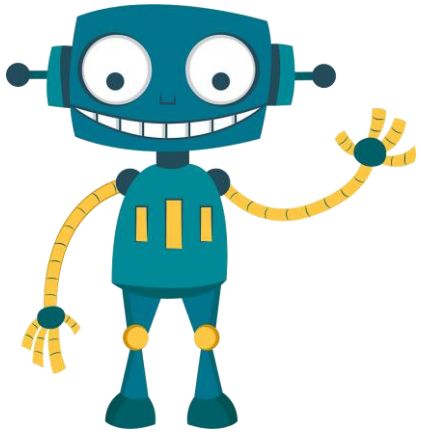

15장 판다스

판다스와 파이썬

- 판다스(Pandas)는 강력한 데이터 구조를 사용하여 고성능 데이터 조작 및 데이터 분석에 사용되는 오픈 소스 파이썬 라이브러리이다.

판다스의 데이터 구조

- 시리즈(Series):

11	73	53	27	52	65	74	98	13	72

- 데이터 프레임(DataFrame):

	이름	나이	성별	평점
0	김철수	19	Male	3.45
1	김영희	22	Female	4.1
2	김명수	20	Male	3.9
3	최자영	26	Female	4.5

행(row)

열(column)

index 객체, columns 객체, values 객체

- 데이터 프레임에서는 행이나 열에 붙인 레이블을 중요시한다.
- index 객체는 행들의 레이블(label)이고, columns 객체는 열들의 레이블이 저장된 객체이다.

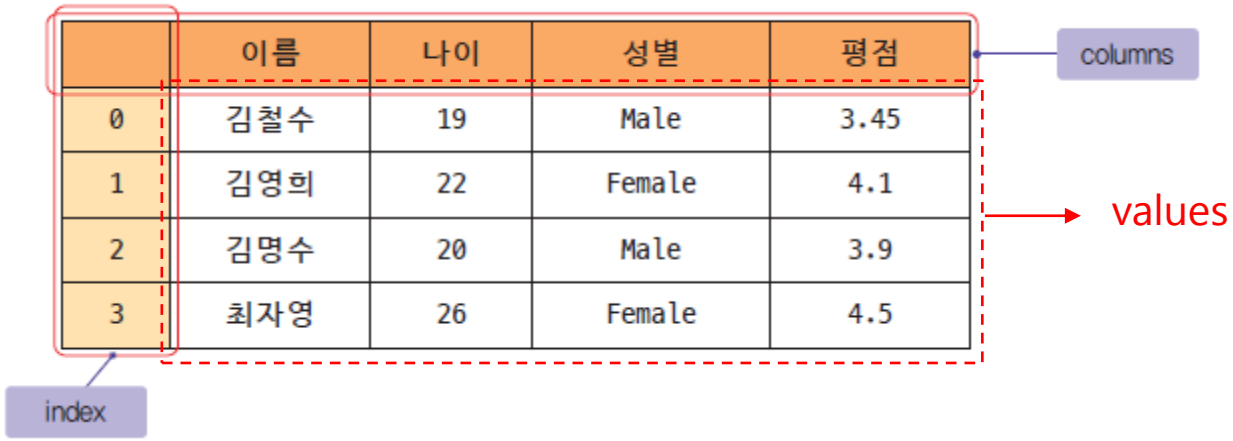

	이름	나이	성별	평점
0	김철수	19	Male	3.45
1	김영희	22	Female	4.1
2	김명수	20	Male	3.9
3	최자영	26	Female	4.5

A dataset is a collection of data.

타이타닉 데이터셋

- 타이타닉호 탑승자에 대한 데이터셋 titanic.csv

PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch
1	0	3	Braund, Mr. Ov	male	22	1	0
2	1	1	Cumings, Mrs.	female	38	1	0
3	1	3	Heikkinen, Mis	female	26	0	0
4	1	1	Futrelle, Mrs. J	female	35	1	0
5	0	3	Allen, Mr. Willi	male	35	0	0
6	0	3	Moran, Mr. Jan	male		0	0

- PassengerId: 승객의 ID • Survived: 생존 여부
- Pclass: 탑승 등급을 나타낸다. 클래스 1, 클래스 2, 클래스 3가 있다.
- Name: 승객의 이름 • Sex: 승객의 성별 • Age: 승객의 나이
- SibSp: Siblings/Spouses, 승객에게 형제 자매와 배우자가 있음을 나타낸다.
- Parch: Parents/Children, 승객이 혼자인지 또는 가족이 있는지 여부.
- Ticket: 티켓 번호 • Fare: 운임 • Cabin : 승객의 선실
- Embarked: 탑승한 지역

CSV 파일을 읽기

```
>>> import pandas as pd
>>> titanic = pd.read_csv("d:\\titanic.csv")
>>> titanic
     PassengerId  Survived  Pclass  ...     Fare Cabin  Embarked
0              1         0       3  ...   7.2500   NaN         S
1              2         1       1  ...  71.2833   C85         C
2              3         1       3  ...   7.9250   NaN         S
3              4         1       1  ...  53.1000  C123         S
4              5         0       3  ...   8.0500   NaN         S
..           ...       ...     ...  ...      ...   ...       ...
886          887         0       2  ...  13.0000   NaN         S
887          888         1       1  ...  30.0000   B42         S
888          889         0       3  ...  23.4500   NaN         S
889          890         1       1  ...  30.0000  C148         C
890          891         0       3  ...   7.7500   NaN         Q
[891 rows x 12 columns]
```

NaN: “not a number”로 데이터가 비었다고 표시

컬럼 추출

```
>> titanic["Age"]
0      22.0
1      38.0
2      26.0
3      35.0
4      35.0
       ...
886    27.0
887    19.0
888     NaN
889    26.0
890    32.0
Name: Age, Length: 891, dtype: float64
```

최대값

```
>>> titanic["Age"].max()
80.0
```

기본 통계

- describe() 메소드는 숫자 데이터에 대한 간략한 개요를 제공한다. 문자열 데이터는 처리하지 않는다.

```
>>> titanic.describe()
       PassengerId    Survived      Pclass  ...       SibSp       Parch        Fare
count   891.000000  891.000000  891.000000  ...  891.000000  891.000000  891.000000
mean    446.000000    0.383838    2.308642  ...    0.523008    0.381594   32.204208
std     257.353842    0.486592    0.836071  ...    1.102743    0.806057   49.693429
min       1.000000    0.000000    1.000000  ...    0.000000    0.000000    0.000000
25%     223.500000    0.000000    2.000000  ...    0.000000    0.000000    7.910400
50%     446.000000    0.000000    3.000000  ...    0.000000    0.000000   14.454200
75%     668.500000    1.000000    3.000000  ...    1.000000    0.000000   31.000000
max     891.000000    1.000000    3.000000  ...    8.000000    6.000000  512.329200

[8 rows x 7 columns]
```

데이터 시리즈 생성하기

- 시리즈는 이름이 붙여진 1차원적인 배열이나 마찬가지이다. 가장 기본적인 방법은 파이썬의 리스트에서 생성하는 것이다.

```
>>> data = ['Kim', 'Park', 'Lee', 'Choi']
>>> ser = pd.Series(data)
>>> ser
0     Kim
1    Park
2     Lee
3    Choi
```

데이터 프레임 생성하기

- 데이터 프레임은 행과 열에 이름이 붙여진 2차원 배열이다.

```
>>> data = {'Name':['Kim', 'Park', 'Lee', 'Choi'],
        'Age':[20, 23, 21, 26]}
>>> df = pd.DataFrame(data)
>>> df
   Name  Age
0   Kim   20
1  Park   23
2   Lee   21
3  Choi   26
```

데이터 프레임 생성하기

- 데이터 프레임에 index를 붙이려면 다음과 같이 index 매개 변수를 사용할 수 있다.

```
>>> data = {'Name':['Kim', 'Park', 'Lee', 'Choi'],
        'Age':[20, 23, 21, 26]}
>>> df = pd.DataFrame(data, index=["학번 1", "학번 2", "학번 3", "학번 4"])
>>> df
        Name  Age
학번 1   Kim   20
학번 2  Park   23
학번 3   Lee   21
학번 4  Choi   26
```

```
>>> df = pd.DataFrame(data)
>>> df
   Name  Age
0   Kim   20
1  Park   23
2   Lee   21
3  Choi   26
```

CSV 파일을 읽어서 데이터 프레임 생성

- 판다스에서 데이터를 읽는 메소드는 read_xxx()와 같은 형태이고, 반대로 데이터를 파일에 쓰는 메소드는 to_xxx()의 형태를 가진다.

```
titanic = pd.read_csv("d:\\titanic.csv")


>>> titanic.dtypes
PassengerId      int64
Survived         int64
Pclass           int64
Name            object
Sex             object
Age            float64
SibSp            int64
Parch            int64
Ticket          object
Fare           float64
Cabin           object
Embarked        object
dtype: object
```

인덱스 변경

- 파일에서 읽을 때 index를 변경할 수 있다. 예를 들어서 첫 번째 열을 index 객체로 사용할 수도 있다.

```
>>> titanic = pd.read_csv('d://titanic.csv', index_col=0)
>>> titanic
             Survived  Pclass  ... Cabin Embarked
PassengerId                    ...
1                   0       3  ...   NaN        S
2                   1       1  ...   C85        C
3                   1       3  ...   NaN        S
4                   1       1  ...  C123        S
5                   0       3  ...   NaN        S
...
```

```
PassengerId,Survived,Pclass,Name,Sex,Age,SibSp,Parch,Ticket,Fare,Cabin,Embarked
1,0,3,"Braund, Mr. Owen Harris",male,22,1,0,A/5 21171,7.25,,S
2,1,1,"Cumings, Mrs. John Bradley (Florence Briggs Thayer)",female,38,1,0,PC 17599
3,1,3,"Heikkinen, Miss. Laina",female,26,0,0,STON/O2. 3101282,7.925,,S
```

데이터 프레임의 몇 개 행을 보려면?

```
>>> titanic = pd.read_csv("titanic.csv")

>>> titanic.head()
 PassengerId  Survived  Pclass  ...     Fare Cabin  Embarked
0            1         0       3  ...   7.2500   NaN         S
1            2         1       1  ...  71.2833   C85         C
2            3         1       3  ...   7.9250   NaN         S
3            4         1       1  ...  53.1000  C123         S
4            5         0       3  ...   8.0500   NaN         S

[5 rows x 12 columns]
>>> titanic.tail(3)
     PassengerId  Survived  Pclass  ...    Fare Cabin  Embarked
888          889         0       3  ...  23.45   NaN         S
889          890         1       1  ...  30.00  C148         C
890          891         0       3  ...   7.75   NaN         Q

[3 rows x 12 columns
```

데이터 프레임을 엑셀 파일로 저장

```
>>> titanic.to_excel('titanic.xlsx', sheet_name='passengers', index=False)

# 이렇게 저장한 엑셀 파일을 다시 읽으려면 다음과 같이 한다.
>>> titanic = pd.read_excel('titanic.xlsx', sheet_name='passengers')
```

난수로 데이터 프레임 채우기

```
>>> df = pd.DataFrame(np.random.randint(0,100,size=(5,4)),columns=list('ABCD'))
>>> df
    A   B   C   D
0  59  71  53  19
1  92  13  88   3
2  69  89   9  77
3  71  47  54   9
4  44  45  90  68
```

Lab: 데이터 프레임 만들기

countries.csv

```
code,country,area,capital,population
KR,Korea,98480,Seoul,48422644
US,USA,9629091,Washington,310232863
JP,Japan,377835,Tokyo,127288000
CN,China,9596960,Beijing,1330044000
RU,Russia,17100000,Moscow,140702000
```

```
>>> import pandas as pd
>>> countries = pd.read_csv('d://countries.csv')
>>> countries
  code country      area     capital  population
0   KR   Korea     98480       Seoul    48422644
1   US     USA   9629091  Washington   310232863
2   JP   Japan    377835       Tokyo   127288000
3   CN   China   9596960     Beijing  1330044000
4   RU  Russia  17100000      Moscow   140702000
```

타이타닉 데이터에서 승객의 나이만 추출하려면?

PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch
1	0	3	Braund, Mr. Ov	male	22	1	0
2	1	1	Cumings, Mrs.	female	38	1	0
3	1	3	Heikkinen, Mis	female	26	0	0
4	1	1	Futrelle, Mrs. J	female	35	1	0
5	0	3	Allen, Mr. Willi	male	35	0	0
6	0	3	Moran, Mr. Jan	male		0	0

Age
22
38
26
35
35

```
>>> ages = titanic["Age"]        # df["col"] 결과는 Series
>>> ages.head()
0    22.0
1    38.0
2    26.0
3    35.0
4    35.0
Name: Age, dtype: float64
```

타이타닉 탑승객의 이름, 나이, 성별을 동시에 알고 싶으면?

```
>>> titanic[["Name", "Age", "Sex"]]      # df[리스트] 결과는 DataFame
                                                 Name   Age     Sex
0                              Braund, Mr. Owen Harris  22.0    male
1    Cumings, Mrs. John Bradley (Florence Briggs Th...  38.0  female
2                               Heikkinen, Miss. Laina  26.0  female
3         Futrelle, Mrs. Jacques Heath (Lily May Peel)  35.0  female
...
```

20세 미만의 승객만 추리려면?(필터링)

```
>>> below_20 = titanic[titanic["Age"] < 20]
>>> below_20.head()
    PassengerId  Survived  Pclass  ...     Fare Cabin  Embarked
7             8         0       3  ...  21.0750   NaN         S
9            10         1       2  ...  30.0708   NaN         C
10           11         1       3  ...  16.7000    G6         S
14           15         0       3  ...   7.8542   NaN         S
16           17         0       3  ...  29.1250   NaN         Q
[5 rows x 12 columns]
```

```
>>> titanic["Age"] < 20
0      False
1      False
2      False
3      False
4      False
```

1등석이나 2등석에 탑승한 승객들을 출력하려면?

- isin() 함수는 제공된 리스트에 있는 값들이 들어 있는 각 행에 대하여 True를 반환한다. df["Pclass"].isin([1, 2])은 Pclass 열이 1 또는 2인 행을 확인한다.

```
>>> titanic[titanic["Pclass"].isin([1, 2])]
     PassengerId  Survived  Pclass  ...     Fare        Cabin  Embarked
1              2         1       1  ...  71.2833          C85         C
3              4         1       1  ...  53.1000         C123         S
6              7         0       1  ...  51.8625          E46         S
9             10         1       2  ...  30.0708          NaN         C
...
[400 rows x 12 columns]
```

```
>>> titanic["Pclass"].isin([1, 2])
0      False
1       True
2      False
3       True
4      False
```

20세 미만의 승객 이름에만 관심이 있다면?

```
>>> titanic.loc[titanic["Age"] < 20, "Name"]
7              Palsson, Master. Gosta Leonard
9        Nasser, Mrs. Nicholas (Adele Achem)
10           Sandstrom, Miss. Marguerite Rut
14      Vestrom, Miss. Hulda Amanda Adolfina
16                      Rice, Master. Eugene
...
Name: Name, Length: 164, dtype: object
```

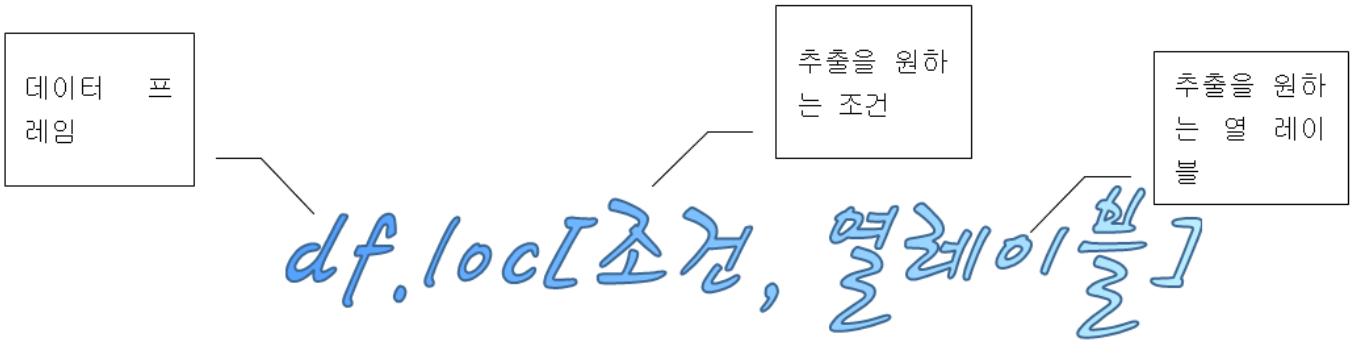

20세 미만의 승객 이름과 나이

```
>>> titanic.loc[titanic["Age"] < 20, ["Name", "Age"]]
                                              Name   Age
7            Palsson, Master. Gosta Leonard   2.0
9       Nasser, Mrs. Nicholas (Adele Achem)  14.0
10          Sandstrom, Miss. Marguerite Rut   4.0
14    Vestrom, Miss. Hulda Amanda Adolfina  14.0
16                     Rice, Master. Eugene   2.0
..                                      ...   ...
[164 rows x 2 columns]
```

20행에서 23행, 5열에서 7열

```
>>> titanic.iloc[20:23, 5:7]      # integer position based
     Age  SibSp
20  35.0      0
21  34.0      0
22  15.0      0
```

데이터를 정렬

```
>>> titanic.sort_values(by="Age").head()
     PassengerId  Survived  Pclass  ...     Fare Cabin  Embarked
803          804         1       3  ...   8.5167   NaN         C
755          756         1       2  ...  14.5000   NaN         S
644          645         1       3  ...  19.2583   NaN         C
469          470         1       3  ...  19.2583   NaN         C
78            79         1       2  ...  29.0000   NaN         S
```

데이터를 정렬하는 방법

```
>>> titanic.sort_values(by=['Pclass', 'Age'], ascending=False).head()
     PassengerId  Survived  Pclass  ...     Fare Cabin  Embarked
851          852         0       3  ...   7.7750   NaN         S
116          117         0       3  ...   7.7500   NaN         Q
280          281         0       3  ...   7.7500   NaN         Q
483          484         1       3  ...   9.5875   NaN         S
326          327         0       3  ...   6.2375   NaN         S
```

열추가

```
>>> countries = pd.read_csv("d:\\countries.csv")
>>> countries["density"] = countries["population"]/countries["area"]
>>> countries
  code country      area     capital  population     density
0   KR   Korea     98480       Seoul    48422644  491.700284
1   US     USA   9629091  Washington   310232863   32.218292
2   JP   Japan    377835       Tokyo   127288000  336.887795
3   CN   China   9596960     Beijing  1330044000  138.590137
4   RU  Russia  17100000      Moscow   140702000    8.228187
```

행추가

```
>>> df = pd.DataFrame({"code":["CA"], "country":["Canada"],
       "area":[9984670],  "capital":["Ottawa"], "population":[34300000]})

>>> df2 = countries.append(df, ignore_index = True)
>>> df2
  code country      area     capital  population
0   KR   Korea     98480       Seoul    48422644
1   US     USA   9629091  Washington   310232863
2   JP   Japan    377835       Tokyo   127288000
3   CN   China   9596960     Beijing  1330044000
4   RU  Russia  17100000      Moscow   140702000
5   CA  Canada   9984670      Ottawa    34300000
```

행삭제

```
>>> countries.drop(index=2, axis=0, inplace = True)
  code country      area     capital  population
0   KR   Korea     98480       Seoul    48422644
1   US     USA   9629091  Washington   310232863
3   CN   China   9596960     Beijing  1330044000
4   RU  Russia  17100000      Moscow   140702000
```

열삭제

```
>>> countries.drop(["capital"], axis=1, inplace = True)
  code country      area  population
0   KR   Korea     98480    48422644
1   US     USA   9629091   310232863
2   JP   Japan    377835   127288000
3   CN   China   9596960  1330044000
4   RU  Russia  17100000   140702000
```

타이타닉 승객의 평균 연령은?

```
>>> titanic["Age"].mean()
29.69911764705882
```

타이타닉 승객 연령과 탑승권 요금의 중간값은?

```
>>> titanic[["Age", "Fare"]].median()
Age     28.0000
Fare    14.4542
```

카테고리별로 그룹화된 통계

```
>>> titanic[["Sex", "Age"]].groupby("Sex").mean()
              Age
Sex
female  27.915709
male    30.726645
```

우리의 관심은 각 성별의 평균 연령이므로 titanic[["Sex", "Age"]]에 의하여 이 두 열의 선택이 먼저 이루어진다. 다음으로, groupby() 메소드가 "Sex" 열에 적용되어 "Sex" 값에 따라서 그룹을 만든다. 이어서 각 성별의 평균 연령이 계산되어 반환된다

카테고리별로 그룹화된 통계

```
>>> titanic.groupby("Sex").mean()
        PassengerId  Survived    Pclass  ...     SibSp     Parch       Fare
Sex                                      ...
female   431.028662  0.742038  2.159236  ...  0.694268  0.649682  44.479818
male     454.147314  0.188908  2.389948  ...  0.429809  0.235702  25.523893

[2 rows x 7 columns]

>>> titanic.groupby("Sex")["Age"].mean()
Sex
female    27.915709
male      30.726645
Name: Age, dtype: float64
```

성별 및 승객 등급 조합의 평균 탑승권 요금은?

```
>>> titanic.groupby(["Sex", "Pclass"])["Fare"].mean()
Sex     Pclass
female  1         106.125798
        2          21.970121
        3          16.118810
male    1          67.226127
        2          19.741782
        3          12.661633
```

각 승객 등급의 수는?

```
>>> titanic["Pclass"].value_counts()
3    491
1    216
2    184
```

데이터로 차트 그리기

- df.plot()은 인덱스를 x축으로, 모든 열(값이 숫자)을 y축으로 그리다.
- df.plot(x='col1')은 col1을 x축으로, 나머지 열은 y축으로 그린다.
- df.plot(x='col1', y='col2')와 같이 호출하면 특정 열에 대하여 다른 열을 그리게 된다

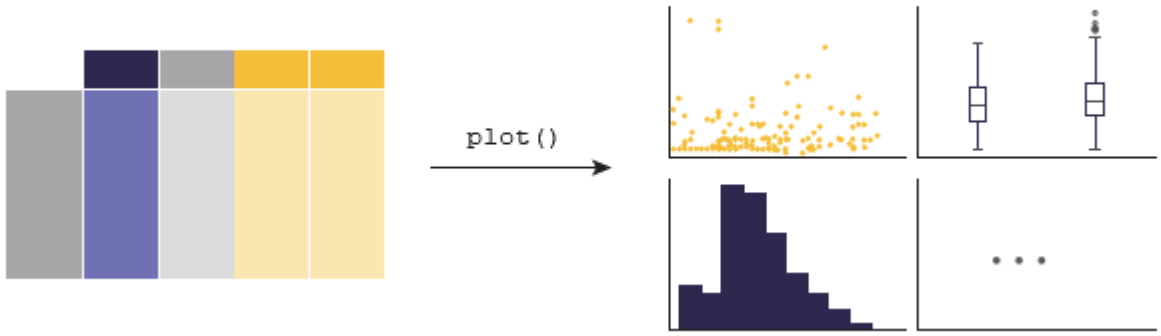

데이터 정의

```
import matplotlib.pyplot as plt
import pandas as pd
df = pd.DataFrame({
    'name':['Kim','Lee','Park','Choi','Hong','Chung','Jang'],
    'age':[22,26,78,17,46,32,21],
    'city':['Seoul','Busan','Seoul','Busan','Seoul','Daejun','Daejun'],
    'children':[2,3,0,1,3,4,3],
    'pets':[0,1,0,2,2,0,3]
})
print(df)
```

```
    name  age    city  children  pets
0    Kim   22   Seoul         2     0
1    Lee   26   Busan         3     1
2   Park   78   Seoul         0     0
3   Choi   17   Busan         1     2
4   Hong   46   Seoul         3     2
5  Chung   32  Daejun         4     0
6   Jang   21  Daejun         3     3
```

그래프

	name	age	city	children	pets
0	Kim	22	Seoul	2	0
1	Lee	26	Busan	3	1
2	Park	78	Seoul	0	0
3	Choi	17	Busan	1	2
4	Hong	46	Seoul	3	2
5	Chung	32	Daejun	4	0
6	Jang	21	Daejun	3	3

```
df.plot(kind='line', x='name', y='pets', color='red')
plt.show()
```

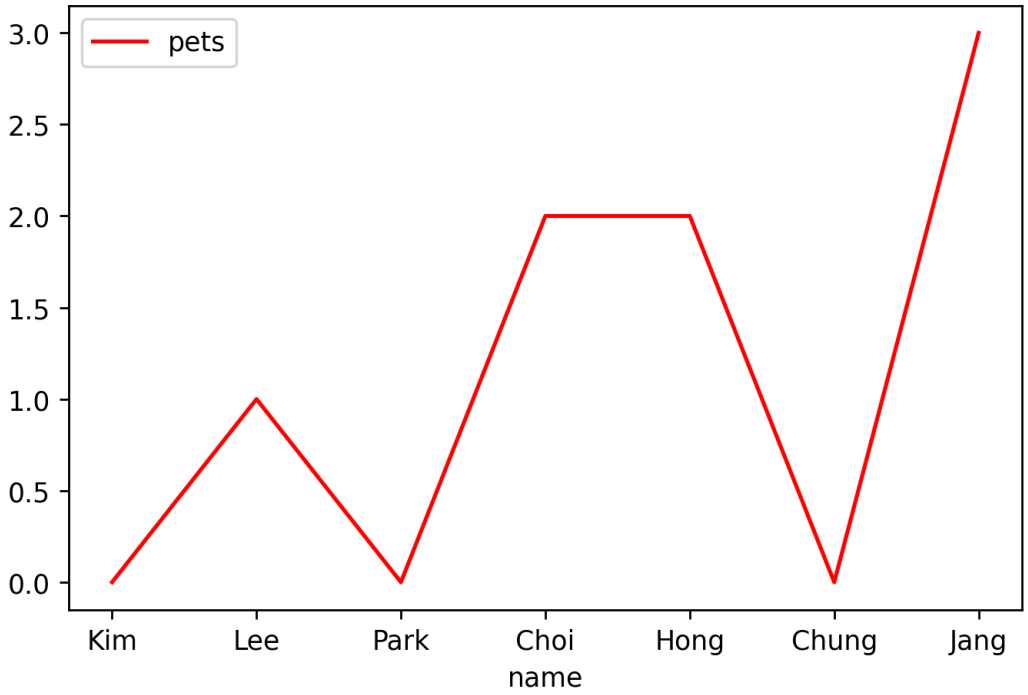

중첩 챠트 그리기

```
ax = plt.gca()

df.plot(kind='line',x='name',y='children',ax=ax)
df.plot(kind='line',x='name',y='pets', color='red', ax=ax)

plt.show()
```

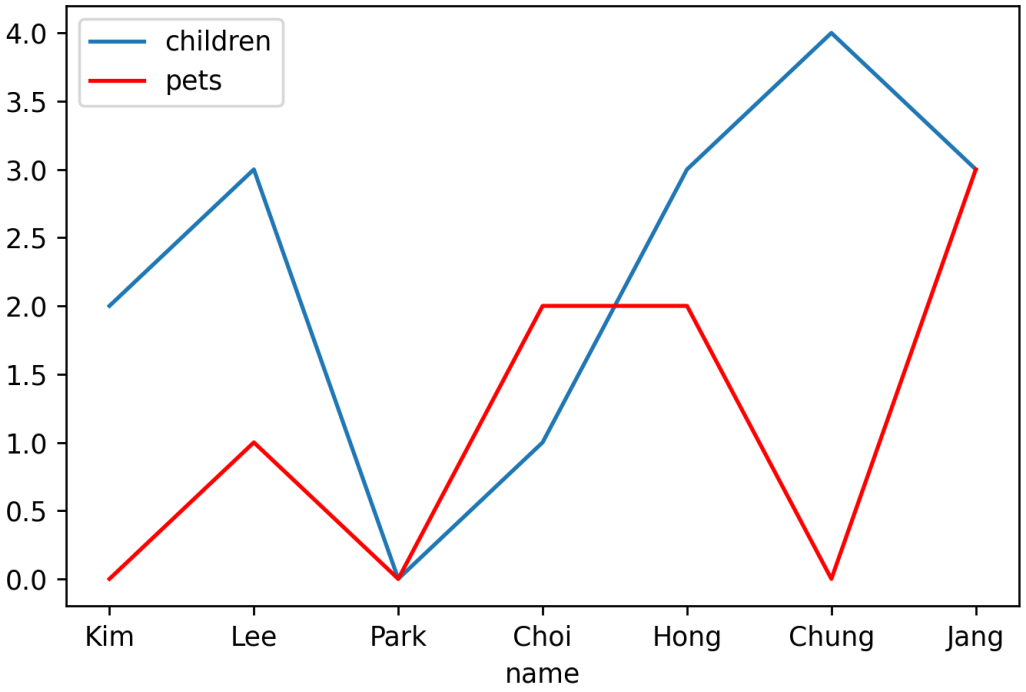

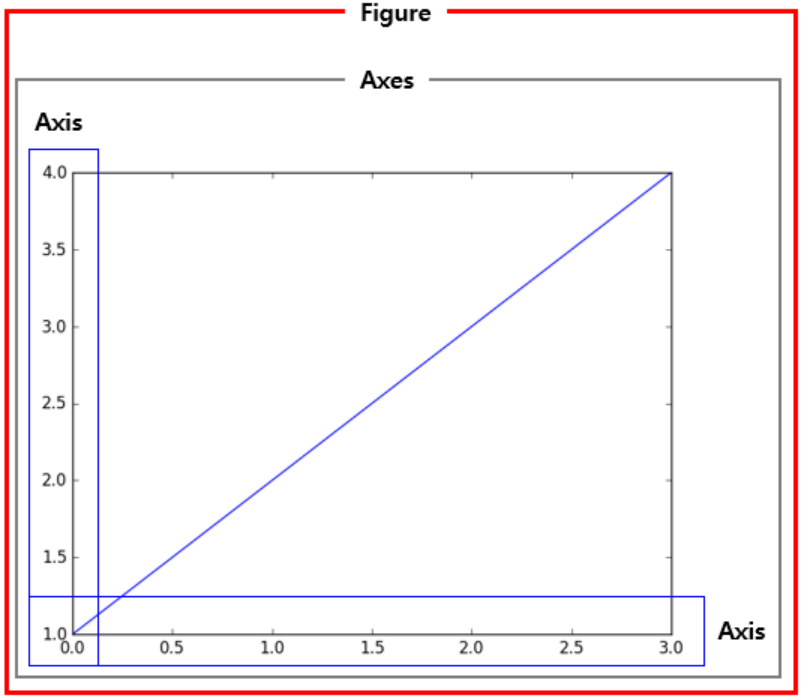

막대 그래프 그리기

```
df.plot(kind='bar',x='name',y='age')
plt.show()
```

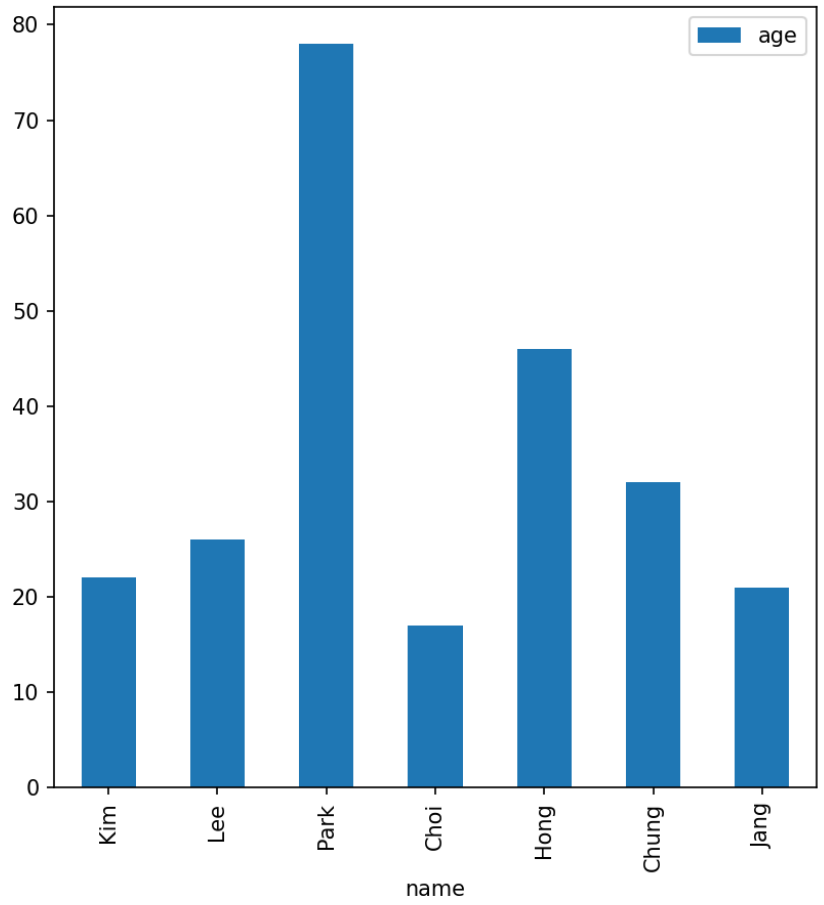

	name	age	city	children	pets
0	Kim	22	Seoul	2	0
1	Lee	26	Busan	3	1
2	Park	78	Seoul	0	0
3	Choi	17	Busan	1	2
4	Hong	46	Seoul	3	2
5	Chung	32	Daejun	4	0
6	Jang	21	Daejun	3	3

산포도 그리기

```
df.plot(kind='scatter',x='children',y='pets',color='red')
plt.show()
```

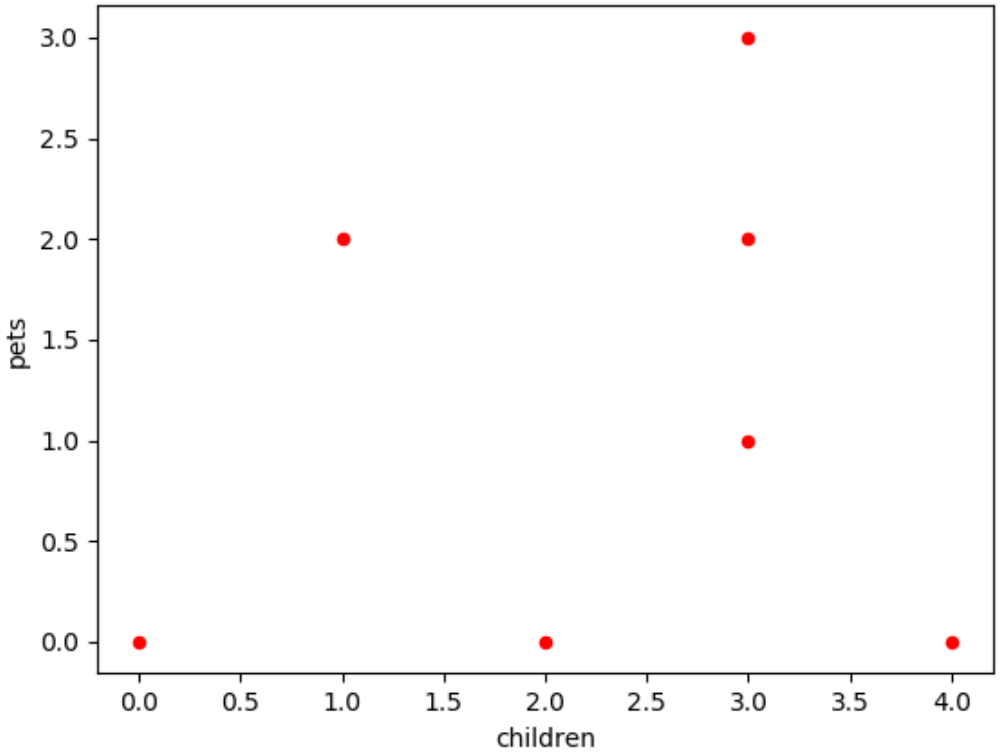

	name	age	city	children	pets
0	Kim	22	Seoul	2	0
1	Lee	26	Busan	3	1
2	Park	78	Seoul	0	0
3	Choi	17	Busan	1	2
4	Hong	46	Seoul	3	2
5	Chung	32	Daejun	4	0
6	Jang	21	Daejun	3	3

그룹핑하여 그리기

```
df.groupby('city')['name'].nunique().plot(kind='bar')
plt.show()
```

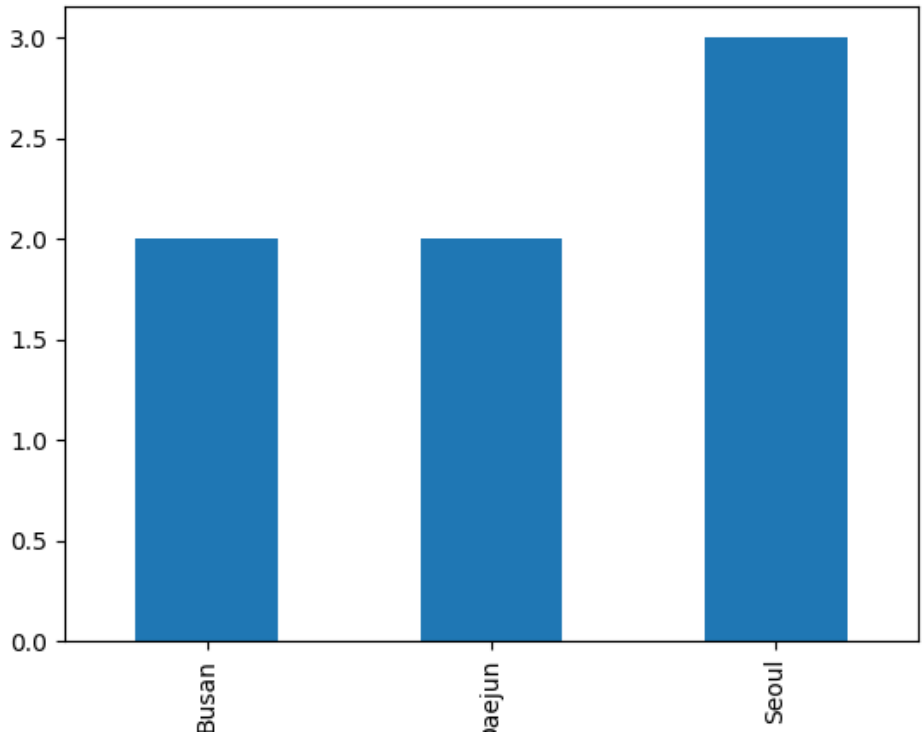

	name	age	city	children	pets
0	Kim	22	Seoul	2	0
1	Lee	26	Busan	3	1
2	Park	78	Seoul	0	0
3	Choi	17	Busan	1	2
4	Hong	46	Seoul	3	2
5	Chung	32	Daejun	4	0
6	Jang	21	Daejun	3	3

히스토그램 그리기

```
df[['age']].plot(kind='hist', bins=[0, 20, 40, 60, 80, 100], rwidth=0.8)
plt.show()
```

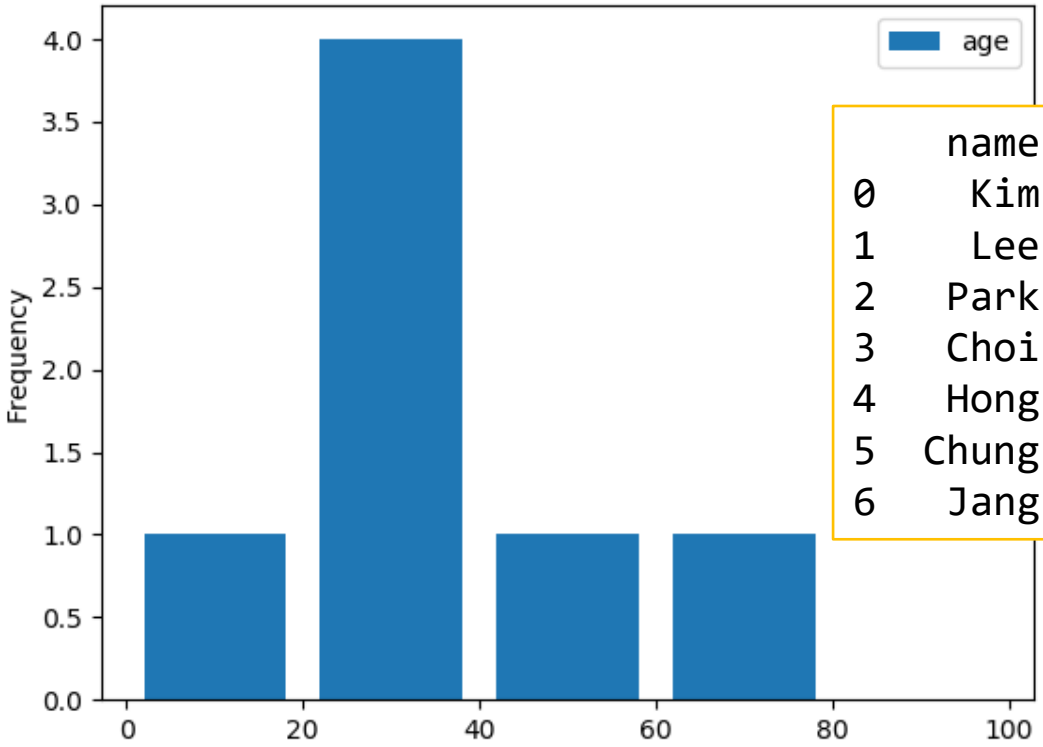

	name	age	city	children	pets
0	Kim	22	Seoul	2	0
1	Lee	26	Busan	3	1
2	Park	78	Seoul	0	0
3	Choi	17	Busan	1	2
4	Hong	46	Seoul	3	2
5	Chung	32	Daejun	4	0
6	Jang	21	Daejun	3	3

피벗 테이블

- 판다스 라이브러리는 값을 깔끔한 2차원 테이블로 요약한 pivot_table()이라는 함수를 제공한다.

학생	과목	성적
홍길동	수학	100
홍길동	과학	95
홍길동	사회	90
최자영	수학	90
최자영	과학	96
최자영	사회	100

학생	수학	과학	사회
홍길동	100	95	90
최자영	90	95	100

사용 데이터

```
>>> titanic.drop(['PassengerId','Ticket','Name'], inplace=True, axis=1)
>>> titanic.head()
   Survived  Pclass     Sex   Age  SibSp  Parch     Fare Cabin Embarked
0         0       3    male  22.0      1      0   7.2500   NaN        S
1         1       1  female  38.0      1      0  71.2833   C85        C
2         1       3  female  26.0      0      0   7.9250   NaN        S
3         1       1  female  35.0      1      0  53.1000  C123        S
4         0       3    male  35.0      0      0   8.0500   NaN        S
```

피벗 테이블에서 인덱스를 사용하여 데이터를 그룹화

```
>>> table = pd.pivot_table(data=titanic, index=['Sex'])
              Age       Fare     Parch    Pclass     SibSp  Survived
Sex
female  27.915709  44.479818  0.649682  2.159236  0.694268  0.742038
male    30.726645  25.523893  0.235702  2.389948  0.429809  0.188908

>>> table.plot(kind="bar")
```

Survived	Pclass	Sex	Age	Embarked
0	3	male	22.0	S
1	1	female	38.0	C
1	3	female	26.0	S
1	1	female	35.0	S
0	3	male	35.0	S

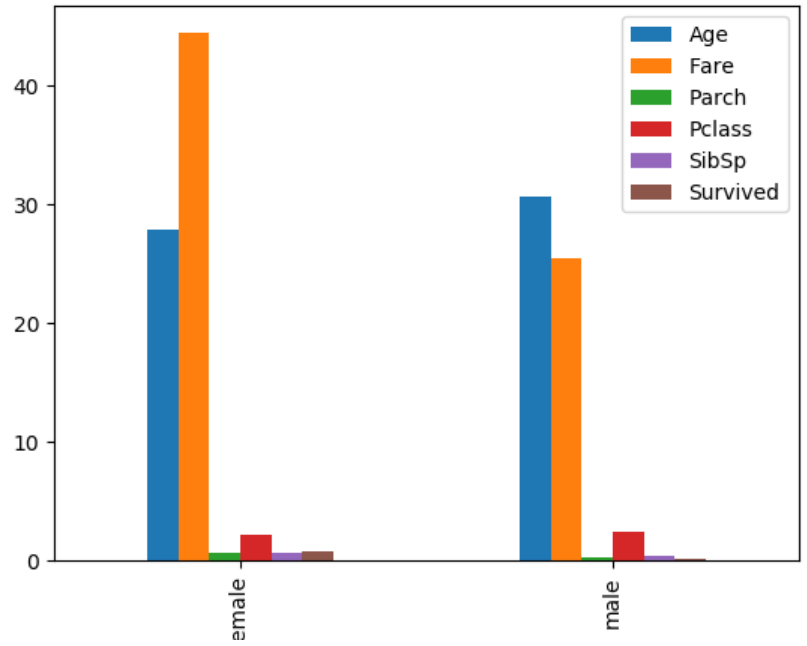

다중 인덱스로 피봇하기

```
>>> table = pd.pivot_table(titanic, index=['Sex','Pclass'])
                     Age        Fare     Parch     SibSp  Survived
Sex    Pclass
female 1       34.611765  106.125798  0.457447  0.553191  0.968085
       2       28.722973   21.970121  0.605263  0.486842  0.921053
       3       21.750000   16.118810  0.798611  0.895833  0.500000
male   1       41.281386   67.226127  0.278689  0.311475  0.368852
       2       30.740707   19.741782  0.222222  0.342593  0.157407
       3       26.507589   12.661633  0.224784  0.498559  0.135447
```

특징별로 다른 집계 함수 적용

```
>>> table = pd.pivot_table(titanic ,index=['Sex','Pclass'],
        aggfunc={'Age':np.mean,'Survived':np.sum})
                      Age  Survived
Sex    Pclass
female 1        34.611765        91
       2        28.722973        70
       3        21.750000        72
male   1        41.281386        45
       2        30.740707        17
       3        26.507589        47
```

Aggregate: 총계

values 매개 변수를 사용하여 특정한 데이터에 대한 집계

```
>>> table=pd.pivot_table(titanic, index=['Sex', 'Pclass'],
        values=['Survived'], aggfunc=np.mean)
               Survived
Sex    Pclass
female 1       0.968085
       2       0.921053
       3       0.500000
male   1       0.368852
       2       0.157407
       3       0.135447

>>> table.plot(kind='bar')
```

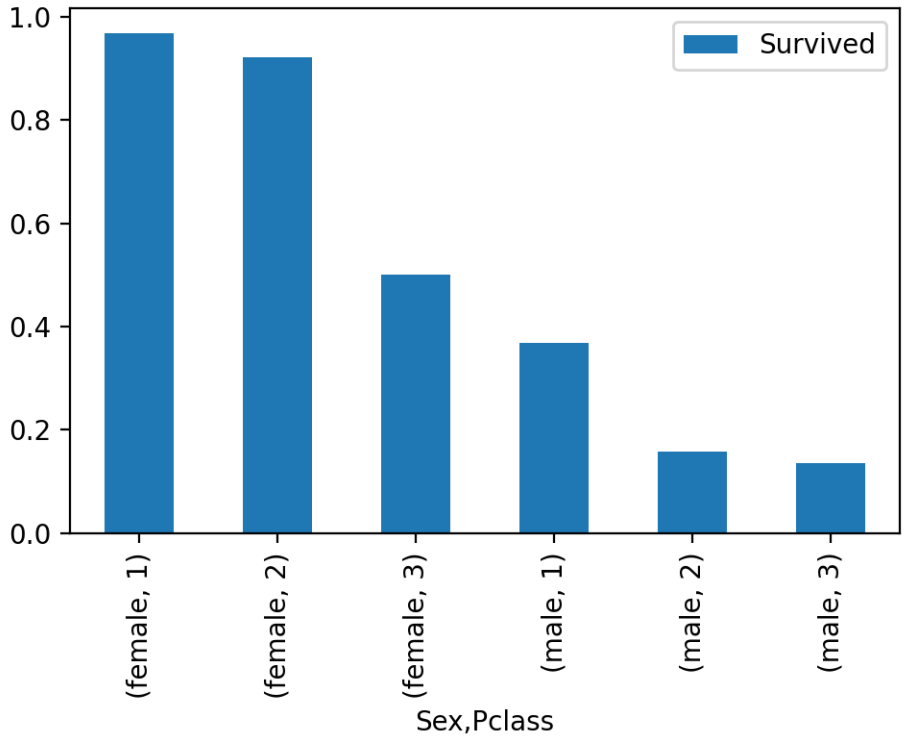

데이터 간의 관계 찾기

```
>>> table = pd.pivot_table(titanic ,index=['Sex'],
        columns=['Pclass'],values=['Survived'],aggfunc=np.sum)

       Survived
Pclass        1   2   3
Sex
female       91  70  72
male         45  17  47

>>> table.plot(kind='bar')
```

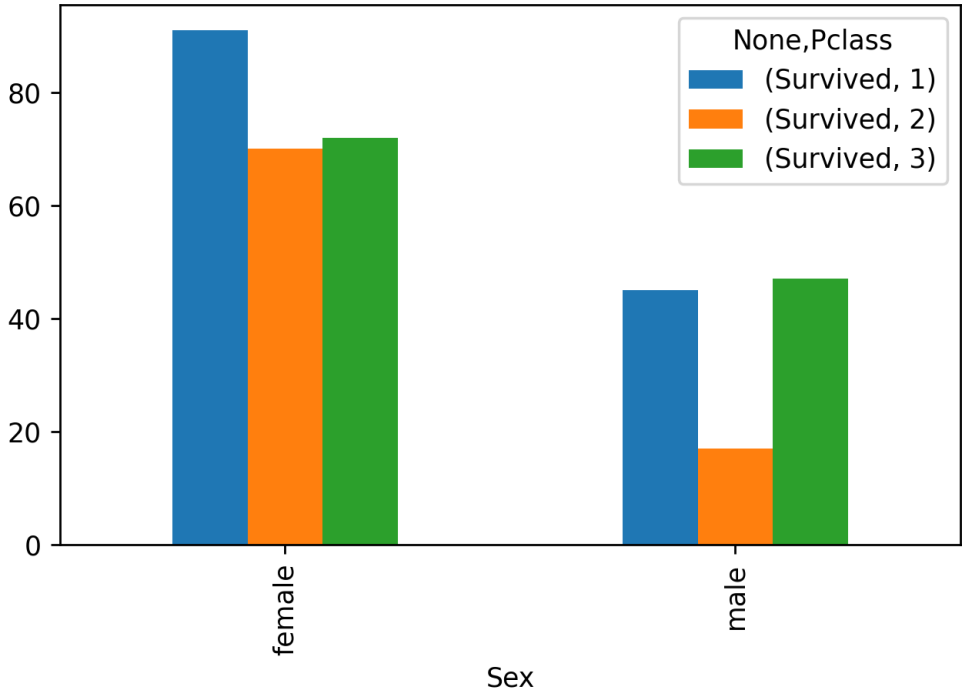

데이터 병합

- merge()을 사용하면 공통 열이나 인덱스를 사용하여 데이터를 결합한다.
- join()을 사용하면 키 열이나 인덱스를 사용하여 데이터를 결합한다.
- concat()을 사용하면 테이블의 행이나 열을 결합한다.

merge()

- merge()를 사용하면 데이터베이스의 조인(join) 연산을 할 수 있다.

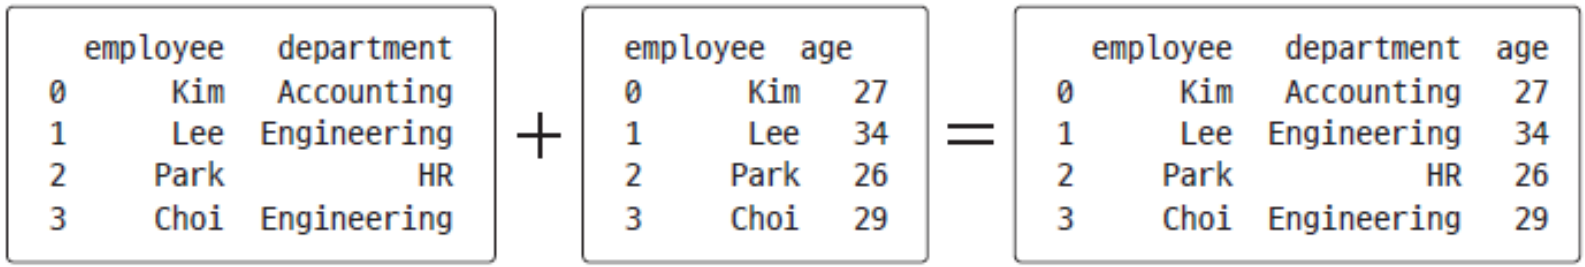

	employee	department
0	Kim	Accounting
1	Lee	Engineering
2	Park	HR
3	Choi	Engineering

+

	employee	age
0	Kim	27
1	Lee	34
2	Park	26
3	Choi	29

=

	employee	department	age
0	Kim	Accounting	27
1	Lee	Engineering	34
2	Park	HR	26
3	Choi	Engineering	29

merge()

```
>>> df1 = pd.DataFrame({'employee': ['Kim', 'Lee', 'Park', 'Choi'],
           'department': ['Accounting', 'Engineering', 'HR', 'Engineering']})

>>> df2 = pd.DataFrame({'employee': ['Kim', 'Lee', 'Park', 'Choi'],
                    'age': [27, 34, 26, 29]})

>>> df3 = pd.merge(df1, df2)
>>> df3
  employee   department  age
0      Kim   Accounting   27
1      Lee  Engineering   34
2     Park           HR   26
3     Choi  Engineering   29
```

결손값 삭제하기

- 실제 데이터셋들은 완벽하지 않다.
- 판다스에서는 결손값을 NaN으로 나타낸다. 판다스는 결손값을 탐지하고 수정하는 함수를 제공한다.

countries1.csv

```
code,country,area,capital,population
KR,Korea,98480,Seoul,48422644
US,USA,9629091,Washington,310232863
JP,Japan,377835,Tokyo,127288000
CN,China,9596960,Beijing,1330044000
RU,Russia,17100000,Moscow,140702000
IN,India,,New Delhi,1368737513
```

결손값 삭제하기

countries1.csv

```
code,country,area,capital,pop
KR,Korea,98480,Seoul,48422644
```

```
>>> import pandas as pd
>>> df = pd.read_csv('d:/countries1.csv', index_col=0)
     country        area     capital  population
code
KR     Korea     98480.0       Seoul    48422644
US       USA   9629091.0  Washington   310232863
JP     Japan    377835.0       Tokyo   127288000
CN     China   9596960.0     Beijing  1330044000
RU    Russia  17100000.0      Moscow   140702000
IN     India         NaN   New Delhi  1368737513
>>> df.dropna(how="any")          # "all"
    country        area     capital  population
code
KR   Korea     98480.0       Seoul    48422644
US     USA   9629091.0  Washington   310232863
JP   Japan    377835.0       Tokyo   127288000
CN   China   9596960.0     Beijing  1330044000
RU  Russia  17100000.0      Moscow   140702000
```

결손값 보정하기

```
>>> df_0 = df.fillna(0)
   country        area     capital  population
code
KR   Korea     98480.0       Seoul    48422644
US     USA   9629091.0  Washington   310232863
JP   Japan    377835.0       Tokyo   127288000
CN   China   9596960.0     Beijing  1330044000
RU  Russia  17100000.0      Moscow   140702000
IN   India         0.0   New Delhi  1368737513
```

```
>>> df.fillna(df.mean()['area'])
   country        area     capital  population
code
KR   Korea     98480.0       Seoul    48422644
US     USA   9629091.0  Washington   310232863
JP   Japan    377835.0       Tokyo   127288000
CN   China   9596960.0     Beijing  1330044000
RU  Russia  17100000.0      Moscow   140702000
IN   India   7360473.2   New Delhi  1368737513
```